

EvoRec

动态物品库生成式推荐系统

产品需求文档与研究实验方案

面向推荐算法实习作品集 | 2026 年 9 月 14 日

研究问题 新商品持续加入时，如何在相同预算下选择合适的检索方式？
目标是提高新物品的推荐机会，同时保持整体质量。

最终作品 强基线复现、动态物品库评估、可验证的算法改进、演示系统与独立复现报告。

状态 文档已完成；系统、模型与实验尚未实施。所有效果和性能指标均为拟定目标。

阅读导航

- 01 项目决策
- 02 产品定位与用户
- 03 范围与最终交付
- 04 研究假设与个人贡献
- 05 数据选择与字段合同
- 06 时间协议与动态物品库
- 07 算法基线与公平比较
- 08 方法设计
- 09 功能需求与验收
- 10 系统结构与接口
- 11 指标与统计口径
- 12 实验矩阵与成功条件
- 13 性能与工程验收
- 14 里程碑与资源计划
- 15 风险与停止规则
- 16 展示与面试验收
- 17 开发启动任务
- 18 参考资料与使用方式

01 项目决策

推荐选择 EvoRec，研究新商品持续加入时，生成式推荐的候选覆盖、冷启动表现，以及生成式与稠密检索之间的计算分配。最终作品是一套可复现实验、一项有明确边界的算法改进，以及能展示新物品加入过程的推荐演示系统。

项目的核心问题是：**在相同的候选数量和推理预算下，能否根据请求的历史信息和当前物品库状态，选择更合适的检索策略，使新物品更容易被找到，同时保持整体推荐质量？**

算法主体使用 Python 与 PyTorch；C++ 用于后期的前缀树、索引快照和推理服务优化。研究优先级高于网站功能与服务规模。项目按研究阶段验收，完整周期参考第 14 节。

这是针对推荐算法实习的选题判断，无法保证录用、论文发表或领先所有候选人。它的竞争力取决于是否真正完成强基线、无泄漏评估、有效改进与独立复现，而不是项目名称或模型参数规模。

为什么选择这个问题

生成式推荐以序列建模方式预测推荐结果。TIGER 研究用语义 ID 表示物品并生成推荐；LIGER 已研究生成式与稠密检索的结合。OpenOneRec 则公开了更大规模的推荐基础模型与训练框架。这些工作说明该方向既有研究价值，也有可参考的实现。[TIGER 论文](#)；[LIGER 官方实现](#)；[OpenOneRec 官方项目](#)。

但共享语义 token 并不等于模型必然会推荐新商品。2026 年的一项预印本从时间切分、未见 token 和语义路径等角度讨论了这一限制。本项目据此选择可检验的问题，而不预先宣称解决了冷启动。[时间视角下的语义 ID 冷启动研究](#)。

与岗位的关系

推荐算法实习需要用户行为建模、机器学习基础、模型训练和实验分析能力。公开的百度推荐算法实习说明也涉及兴趣建模、序列推荐和排序优化。EvoRec 能展示这些能力中的一部分；数学基础、论文理解和编程能力仍需要单独准备。[百度推荐算法实习岗位说明](#)。

02 产品定位与用户

产品形态是“推荐实验工作台 + 动态商品推荐演示”。研究者可以重放历史请求、比较策略和分析失败原因；浏览者可以查看推荐列表，并观察商品库更新前后推荐结果的变化。

用户	核心需求	完成标志
推荐算法研究者	用同一协议公平比较多种模型	一条实验配置生成可追溯的结果表
推荐业务开发者	新商品加入后能参与推荐	新快照发布后，合格商品进入候选库
演示系统浏览者	得到与历史兴趣相关的商品	展示真实可用商品，支持新用户回退
面试官或复现者	判断工作是否可信且由作者理解	能复现关键表格，并追问设计与失败案例

业务场景采用电商商品发现。用户可能长期购买某类商品，近期开始关注另一主题；平台同时不断添加新商品。系统需要从当前有效商品库中生成 Top 10 推荐。

第一版不要求交易、支付、商家管理或真实流量。目标是研究推荐效果与计算成本，不以业务功能数量评判完成度。

03 范围与最终交付

必须完成的研究范围

- 1. 构建可追踪物品加入时间的离线协议，明确数据能支持与不能支持的结论。
- 2. 复现流行度、ItemCF、SASRec-CE、内容感知稠密检索、TIGER 与 LIGER。
- 3. 分析语义 token、前缀支持、碰撞、解码截断与冷启动失效的关系。
- 4. 提出并检验预算约束下的请求级检索路由；与最强固定策略公平比较。
- 5. 完成至少两个商品领域、三个随机种子的主实验和关键消融。
- 6. 提供动态商品库演示、实验报告、复现入口和贡献说明。

有条件加入的扩展

HSTU 用于补充更强的序列建模对照；OpenOneRec 用于工业架构学习或单独的迁移实验。二者不等同于 TIGER 的语义 ID 自回归检索，必须说明任务与候选口径的区别。[Meta 官方项目](#)。

图像特征、强化学习后训练、跨领域迁移、大模型指令推荐均属于后续独立研究，不同时进入首轮主实验。扩展必须回答新增问题，不能只增加技术名词。

交付清单

编号	交付物	内容
D01	项目仓库	环境锁定、数据脚本、模型、评估、测试、运行入口
D02	数据卡与协议	切分时间、过滤量、字段可用性、物品库定义
D03	基线复现报告	官方结果复现与项目协议结果分表呈现
D04	算法研究报告	假设、方法、消融、置信区间、失败案例
D05	演示系统	用户历史、策略对比、新商品加入与快照回滚
D06	推理性能报告	硬件、延迟、吞吐、显存、候选预算与测量边界
D07	面试材料	架构图、三分钟演示、贡献清单、简历实测表述

04 研究假设与个人贡献

H1 语义路径支持与冷物品表现存在关系

待检验：在控制物品训练频次、内容质量与用户历史长度后，训练中较少出现的语义前缀是否仍与较低的冷物品召回相关。先做分组诊断和 Oracle 前缀实验，再决定是否需要改模型。Oracle 实验向诊断程序提供目标的正确前缀，只用于定位错误，绝不计入可部署方法的效果。

严格区分“理论不可达”和“概率很低”。物品不在当前库、ID 不可表示或被硬约束排除，才属于结构上的不可达；某个前缀从未训练过，并不自动意味着它在数学上无法生成。

H2 按请求分配检索预算优于固定混合

待检验：只使用请求到达时可见的历史与物品库信息，选择稠密检索、生成式检索或二者混合，是否能改善推荐效果与计算消耗之间的关系。主要对手是经过调参的固定混合策略与 LIGER，而非只有热门推荐。

H3 路由收益能跨领域和更新阶段保持

待检验：第一领域确定的方法，在第二领域按预先约定的有限调参预算下能否保持趋势；模型冻结期间，随着物品库更新，收益是否会消失。不能只挑选一个有利数据集、一个种子或一段时间。

贡献边界

“生成式 + 稠密检索”已有相关工作，本项目不将其视为首创。个人贡献候选是：动态物品库评估协议、可达性诊断实现、预算路由方法、严谨的比较结果，以及这些结论对应的代码。是否构成论文创新，需要更全面的相关工作审查与实际实验支持。

如果简单固定策略与复杂路由一样好，报告应保留该结论，并选择简单策略部署；不要为保留“创新点”而弱化基线。

05 数据选择与字段合同

主数据

使用 Amazon Reviews 2023，首个领域为 Video_Games，第二个领域为 Toys_and_Games。第三个领域作为后续外部验证，由训练阶段的数据量与完整性确定，不能按测试集收益选择。原始数据包含评论行为、时间戳与商品元数据；商品关联使用 parent_asin。[数据官方说明](#)。

使用原始数据或官方 0-core 交互作为入口。不能只用全量 5-core 过滤后的数据研究冷启动，因为这会改变低频物品与用户的分布。论文复现轨允许遵循原论文过滤方式，但须单独标记。

这里预测的是“下一次被记录的商品交互”。评论时间不是准确购买时间，未交互也不等于不喜欢；因此主结果不能写成点击率、转化率或真实购买提升。

字段	用途	时间和使用约束
user_id	构造历史与用户级统计	映射后保存，不用于身份识别
parent_asin	商品主键	同一商品跨快照保持稳定

字段	用途	时间和使用约束
timestamp	排序与切分	明确单位，严格排除未来行为
rating	辅助分组分析	主任务不把低评分记录直接删成“无行为”
商品标题与类别	内容编码与展示	静态元数据快照，注明历史可得性限制
商品描述与特征	扩展内容表示	首轮只用标题与类别，控制变量后加入
评论正文与评论标题	不进入主模型输入	目标评论包含事后信息，存在泄漏风险
总评分数与平均评分	禁止进入主特征	数据抓取时统计可能包含未来信息

主任务用全部有效评论记录表示被观测交互，去重后保留同一用户与商品的最早一次交互。若研究评分大于等于 4 的偏好任务，必须新建任务版本并重跑全部对照，不能混用指标。

数据处理要求

流式读取，校验主键、时间范围、空文本与重复行。每一步记录输入量、输出量和剔除原因。用户活跃阈值、词表、频次、归一化参数与码本学习仅依赖训练可见数据。

保留缺少元数据的商品，使用固定缺失内容表示并单独统计。纯内容模型可能无法有效区分这些商品，这属于实际限制；主结果不能通过仅保留有文本的样本来掩盖它。

模型训练、数据和第三方代码的许可分别记录。发布自己的代码与处理脚本，原始数据按官方渠道获取；不能把下载到的数据默认当作可以整包重新分发的素材。

06 时间协议与动态物品库

两条轨道分别报告

R 轨为论文复现。 遵循 TIGER 或 LIGER 原始协议，记录数据版本、过滤、候选集和评估实现。目标是验证实现，不将该轨结果直接解释为动态上线效果。

D 轨为项目主实验。 按全局时间切分并冻结模型，重放物品库更新与用户历史变化。默认使用 Amazon 官方 timestamp 切分所提供的两个时间点，具体值与单位必须在下载的官方版本中校验并写入 manifest；不得静默替换为逐用户留一法。[官方切分脚本说明](#)。

训练区间为 $t < T1$ ，验证区间为 $T1 \leq t < T2$ ，测试区间为 $t \geq T2$ 。模型只用训练区间拟合；验证用于参数选择，测试在方案冻结后运行。相同时间戳的事件作为一组处理，不互相提供历史。

物品加入时间的实际限制

该数据不提供完整、可靠的历史上架记录。D 轨采用“第一次观测到交互的时间”作为物品可见时间代理：处理时间 t 的请求时，仅允许 $first_seen < t$ 的物品进入候选库。当前请求的目标不能因评估器知道答案而提前插入。

这是一种保守的动态物品库代理，**不等同真实上架历史**。商品首次出现的请求可能无法被推荐，应同时报告“全事件结果”和“目标已入库事件结果”，以及不可入库目标比例。所有方法使用同一可用商品集。

静态商品文本也不是历史版本。本项目因此只能声称在“时间隔离的交互 + 静态内容快照 + 首次观测入库代理”上评估，不能声称完成完全历史无泄漏的线上复现。需要验证文本预训练模型是否可能接触数据，并报告其版本、发布时间及未知之处。

冷启动的精确定义

分组	定义	可以说明什么
Warm	T1 前至少有一次训练交互	模型有机会学习该商品的协同信号
Model-cold	T1 前零训练交互，当前已入库	模型未用该商品交互训练，但物品库已可见
Head 与 Tail	按训练频次划分并冻结阈值	检查流行度偏差，不能用测试频次分组
首次出现目标	first_seen 等于当前时间	本代理协议下尚不可推荐，计入全事件失败
零反馈上架模拟	人工设置元数据先于行为入库	仅说明受控模拟，不证明真实零反馈效果

Model-cold 不等于当前从未有任何反馈：测试期较早的交互可能已使它入库。主文必须保持这一差别。真正零反馈新商品的研究作为独立模拟附录，公开上架时刻生成规则与随机种子。

历史与训练的隔离

评估时允许把已经发生的早期验证或测试交互更新到用户历史，这是预先声明的顺序重放；不据此更新模型权重、训练统计或码本。预测当前请求后才更新历史。离线真值只交给评估器，服务接口中不存在 target_item_id。

同一用户历史只保留过去的有效事件；输入序列最多取最近 100 条，已交互过滤使用完整可见历史。新用户使用内容或热门回退，并单独报告。

07 算法基线与公平比较

基线	作用	必须锁定的公平条件
Popularity	检查频次是否已解释主要收益	仅训练频次，动态库过滤一致
ItemCF	检查简单协同是否足够	训练交互范围一致，不使用未来共现
SASRec-CE	强序列 ID 基线	完整 softmax 或清楚标注近似损失
内容感知稠密检索	冷物品可泛化的主要对手	内容编码器、历史与候选库一致
TIGER	语义 ID 生成式基线	码本、解码预算与碰撞处理清楚可查
LIGER	最接近的混合检索工作	官方复现与动态适配结果分开
固定混合与规则路由	检验学习路由是否必要	相同候选上限和预算调参机会

SASRec 不能仅用一个未经调参的弱实现；建议以全交叉熵版本为主，并明确它与原论文训练方式的区别。相同模型名称不代表相同训练协议。[SASRec 论文](#)；[序列推荐时间切分研究](#)。

内容感知稠密检索采用“用户序列编码器 + 商品内容向量投影”，训练用户与下一交互商品的匹配。以精确全库打分为质量参照，ANN 结果另外报告相对精确检索的召回损失。可复用 Faiss 构建索引。[Faiss 官方文档](#)。

所有模型使用相同的训练标签范围。首轮为每个可训练模型分配相同数量的有效调参试验，同时记录 GPU 小时；报告中同时给出等调参预算和等推理预算视角，不能通过额外训练或更多候选制造收益。

08 方法设计

8.1 商品内容与语义 ID

固定文本编码器版本和输入模板，将标题与类别编码为内容向量。第一轮复现优先采用基线配置；任何编码器替换均作为新实验，不能把更强的文本模型带来的收益算给路由器。

RQ-VAE 将连续向量编码为多个离散 token，类似给商品分配一串共享语义地址。码本只在训练允许的商品内容上学习。建议首轮尝试 3 层、每层 256 个码字，最终选择由验证集决定，不能预先把这些数值当成最优。

码本冻结后，新商品可以被映射到已有 token 空间。保留语义 ID 到商品集合的映射，显式记录碰撞。TIGER 原始复现遵循其唯一化方法；项目动态实现若改用“语义桶生成 + 桶内排序”，必须标为适配版本。

动态实现中，同一语义 ID 对应多个商品时，使用共同的内容匹配分数在桶内截断；不能在离线评估时把真实目标直接补入候选。桶扫描与桶内排序均计入预算，超大桶必须有确定的上限与溢出日志。

8.2 生成式检索

用户过去交互的语义 ID 序列进入编码器，解码器预测下一商品的语义 token。训练采用逐 token 的交叉熵；推理使用当前物品库的前缀树约束，返回合法语义路径，再映射为候选商品。

生成式候选分数使用路径对数概率，不直接与稠密向量点积相加。不同语义桶的大小可能影响结果，需通过分桶报告与消融检查。主实验冻结长度归一化、去重及同分排序规则。

8.3 请求级预算路由

路由器在昂贵检索前选择动作。初始动作集如下，数值是试验起点；最终每个动作的真实成本由性能测量确定。

动作	检索路径	最大合并候选数
D	稠密检索 200 个候选	200
G	生成式检索并映射商品	200
H	生成式 100 个与稠密 100 个合并	200

所有动作在相同候选集合接口后使用同一个内容感知评分器输出 Top 10，因此主消融聚焦候选检索与预算。纯生成式直接排序作为额外结果单独呈现。本项目不把这条混合链路称为完全单阶段推荐。

初始路由特征包括历史长度、历史训练频次分布、最近行为间隔、历史中未训练商品占比、当前新增商品比例以及可复用的用户向量。所有统计有明确截止时刻。

禁止使用当前真实目标、是否命中、目标冷暖标签或尚未计算的昂贵检索结果。若使用生成器熵或前缀支持作为探测特征，必须先执行探测，并把探测时间和 GPU 开销计入总成本；不可把两路都跑完再称为节省检索。

8.4 路由训练

在训练区间内做滚动交叉拟合：较早历史训练基础模型；对随后一段请求离线运行所有候选动作，记录各动作的推荐效果与实际成本；继续向后滚动。预测一个训练样本的基础模型不得见过它的目标。D 轨的码本在最早拟合窗口训练后冻结，后续窗口仅编码新商品；训练统计和索引均按各折的时间边界重建。

用这些样本训练一个小型多层感知机，预测动作效用或动作选择。概念目标为“推荐质量减去计算成本惩罚”，惩罚权重在验证集选择。不要把研究问题复杂化为必须使用强化学习；监督路由是首个待验证方案。

最后，基础检索模型用完整训练区间重新拟合，路由器保留滚动样本训练结果，并在验证期校准。基础模型变化会使路由特征分布变化，必须检查校准误差；若明显失效，保留固定混合方案并说明原因。

基础模型、路由器和固定策略均不读取验证或测试真值拟合参数。验证真值只用于事先限定的模型选择；各基线同样有完整训练区间和调参机会。

8.5 合法性与回退

所有结果必须属于请求捕获的有效物品库、去重且符合已交互过滤规则。候选不足时优先以当前库中的稠密或热门结果补齐，并记录回退；禁止静默伪装为纯生成式成功。

无历史用户返回当前可用热门与类别多样化列表；内容缺失新商品单独分组；无法取得有效模型时返回服务不可用状态。超时允许使用已完成的候选，响应必须说明 degraded 与实际动作。

09 功能需求与验收

优先级 P0 表示形成研究结论所必需，P1 表示增强作品展示与工程深度，P2 表示独立扩展。以下需求均为待实现。

编号	级别	功能	验收条件
F01	P0	数据导入与数据卡	相同输入与配置产生相同哈希及过滤统计
F02	P0	时间重放	修改未来行为不改变此前请求的输入与物品库
F03	P0	基线训练	每个模型保存配置、提交号、种子与权重
F04	P0	语义编码与诊断	能导出 token 使用率、碰撞率及路径支持统计
F05	P0	公共候选接口	每条候选携带来源，禁止补入评估真值
F06	P0	路由与成本记录	路由只依赖允许特征，探测成本完整计入
F07	P0	统一离线评估	所有方法使用同一事件集合与物品库快照
F08	P0	增量商品入库	冻结模型与码本，新商品可加入合法候选库
F09	P0	快照发布与回滚	请求期间索引与映射版本一致，回滚可复现

编号	级别	功能	验收条件
F10	P1	商品推荐演示	展示历史、候选来源与最终 Top 10
F11	P1	实验工作台	展示指标、分组、资源成本和失败案例
F12	P1	C++ 关键路径	与参考实现结果一致，并给出实测收益
F13	P2	外部大模型迁移	单列训练来源、可能的数据重叠与资源成本


页面行为

推荐页包含用户或示例历史选择、Top 10 商品与可选策略对比。算法名称与分数放在“研究详情”中，普通浏览区展示标题、类别和历史关联信息。历史关联只是解释性展示，不把注意力权重当作因果解释。

物品库演示页支持从自制示例商品文件导入一批新商品，显示构建状态、当前版本和是否已生效。更新失败保留旧版本，并展示可理解的错误原因。

实验页从真实报告文件读取结果；未运行的表格显示“未运行”，不能预填预期收益。允许按 Warm、Model-cold、Tail 和时间窗口筛选，并始终显示样本数。

10 系统结构与接口



模型与物品库均有版本，单次请求持有一致快照

离线流程为：原始交互与元数据 → 时间切分与数据卡 → 内容编码与语义码本 → 基线及路由训练 → 冻结模型包 → 统一评估与报告。

在线演示流程为：请求与过去历史 → 捕获物品库快照 → 路由动作 → 生成式或稠密检索 → 统一评分与过滤 → Top 10 与运行记录。

先使用模块清晰的 Python 单服务，模型、评估器和数据处理保持独立。研究稳定后再加入 C++ 组件。前端保持简洁，模型实验不依赖前端才能运行。

接口	用途	关键输入或输出
POST /v1/recommend	生成推荐	user_id、history、as_of、top_k、budget_tier
POST /v1/catalog/batches	提交演示商品批次	batch_id、items、content_schema

接口	用途	关键输入或输出
GET /v1/catalog/jobs/{id}	查询构建进度	pending、building、validated、active、failed
POST /v1/catalog/activate	激活已验证快照	snapshot_id、expected_previous_id
POST /v1/catalog/rollback	回退到上一有效快照	snapshot_id
GET /v1/experiments/{id}	读取实验报告	metrics、slices、manifest、artifacts
GET /health	检查就绪状态	model_version、snapshot_id、ready

recommend 响应包含 request_id、model_version、tokenizer_version、snapshot_id、selected_action、actual_action、latency_ms、degraded 和 items。每个 item 包含稳定主键、rank、score 和 retrieval_sources。score 是模型匹配分数，不标为点击概率。

top_k 默认 10，范围 1-50；history 超长按已公布规则截断。未知版本、非法时间和格式错误返回明确错误。管理员接口仅用于本地或受保护的演示环境。

模型包包含模型权重、内容编码器版本、码本、特征 schema、tokenizer、配置与训练截止时间。物品库快照包含 SID 映射、前缀树、稠密索引、元数据与有效性过滤状态，并声明兼容的模型和码本版本。

新商品更新先在旁路构建完整快照，完成一致性校验后原子切换。正在处理的请求继续持有旧快照，直到请求结束才释放；同一次请求不能混用新旧前缀树和物品映射。

11 指标与统计口径

推荐质量

主指标为全事件 NDCG@10；同时报告目标已入库事件 NDCG@10、Recall@20 和候选 Recall@200。单个请求只有一个下一交互目标时，Recall@K 与 HitRate@K 等价，不把它们当作两个独立收益。

目标排名为 r 且 $r \leq K$ 时，单目标 NDCG@K 为 $1 / \log_2(r + 1)$ ，否则为 0。全事件口径中尚未入库目标标记为 0；条件口径剔除此类事件，但必须明确分母与占比。

先计算每位用户在评估期内各请求的平均值，再做用户平均，作为主汇总；事件平均作为补充。Warm、Model-cold 与 Tail 使用相同汇总规则，显示用户数、事件数和可推荐目标覆盖率。

诊断与成本

指标	用途
结构可达目标比例	检查有效库、可表示 ID、前缀树和映射是否允许目标
前缀支持分布	检查低频路径与召回失败的关系
无效输出率与回退率	揭示非法路径、候选不足和故障
Item Coverage@10	至少推荐一次的商品数占同期可用商品并集的比例
路由动作占比	检查是否退化为固定动作
p50 与 p95 延迟	衡量单请求与尾部响应时间
吞吐与 GPU 时间	衡量并发能力及计算资源消耗
新物品入库耗时	从提交到新快照可用，内容编码单独拆分

不使用全库均匀负采样 AUC 作为主结果。精确全库评估与 ANN 评估必须分开；若使用采样评估做调试，标注候选采样规则，不与主表混用。

统计要求

主实验至少三个随机种子，保留每个种子的原始值、均值与标准差。以用户为簇做配对 bootstrap，报告改进差值的 95% 置信区间；随机种子间波动另外报告，不把两类不确定性混成一个数字。

预先固定主要比较与主要指标。其他分组和大量消融属于探索性结果，不能在几十个比较中只选显著的几个宣称普遍有效。冷组样本不足时只做描述，不强行报告稳定优势。

12 实验矩阵与成功条件

核心实验

编号	实验	要回答的问题
E01	官方复现	代码能否达到相近结果，偏差来自哪里
E02	全局时间与动态库比较	切换到真实约束代理后模型排序是否变化
E03	六类基线与最强固定混合	改进是否超越有竞争力的对手
E04	学习路由与规则路由	模型选择是否比简单规则更有价值
E05	去掉时间与物品库特征	收益是否来自动态环境信息
E06	无探测与有成本探测	额外探测是否值得付出开销
E07	改变 beam 与 ANN 深度	收益是否仅来自更多检索计算
E08	冷暖与路径支持分组	对谁有效，对谁无效，机制是否一致
E09	多快照连续重放	冻结模型面对新增商品是否逐渐退化
E10	第二领域与三个种子	收益是否可以稳定复现

每项实验保存唯一 run_id、代码提交号、数据与物品库哈希、切分配置、种子、超参数、硬件、运行时长和结果路径。失败运行也保存记录。

目标不是既成事实

研究目标 A：在与最强固定策略相同的 p95 延迟约束下，提高 Model-cold Recall@20，并保持整体 NDCG@10。

研究目标 B：在整体 NDCG@10 相对退化不超过 1% 的预先声明容忍范围内，相比最强固定混合降低至少 20% 的平均计算时间。

上述阈值是启动时的目标，不是保证达成的验收数字。研究结论以置信区间和实际成本为准；“均值看起来更高”不等于稳定改进。即使 A 与 B 均未达成，也要完成结果分析，不能反复试探测试集后改口径。

完成与优秀的区别

完成线是协议正确、基线可信、主实验可复现、方法局限交代清楚。具有明显竞争力的作品还应做到：至少一个核心假设获得跨种子支持，与最接近强基线的差异能解释，第二领域有验证，且第三方可以复现关键结果。

投稿级目标还需要系统文献审查、对已有方法的充分比较和更强实验支撑；本 PRD 不预判项目能达到投稿标准。

13 性能与工程验收

质量比较先使用同一硬件和相同请求集合，分别测量 batch=1 延迟以及固定批量吞吐。预热、数据传输、CPU 预处理、路由、探测、检索和排序都要列出计时边界。GPU 异步操作必须同步或使用正确事件计时。

演示初始目标为 Top 10 请求 p95 小于 300 ms，错误率低于 1%；这些数值只有在指定硬件、模型规模、候选上限和负载下才有意义，首轮测量后冻结验收配置。训练任务与性能测试隔离，禁止将单请求峰值包装成持续吞吐。

C++ 版本先保证与 Python 参考实现输出一致，再比较速度。测试涵盖空前缀、碰撞桶、无效商品、同分稳定顺序、快照切换和并发读。若没有实测优势，保留参考实现并解释瓶颈。

必须自动验证的边界包括：未来行为不能改变过去结果；当前目标不进入路由输入；真实目标不被候选阶段强行补齐；内容编码与码本版本不兼容时拒绝激活；回滚后相同请求产生相同的确定性结果。

14 里程碑与资源计划

不以最低难度作为选题约束，但仍按依赖顺序推进。参考工作量为 14-20 周，每周约 25-35 小时；这是规划估计，不是对你现有基础或设备的判断。若 PyTorch、概率和优化基础尚未建立，需先补相应阶段。

阶段	参考时间	必须完成的结果	进入下一阶段的条件
M0	第 1-2 周	理解任务、阅读核心论文、数据卡草案	能手算交叉熵与 NDCG，解释数据泄漏
M1	第 3-4 周	数据协议、热门与 ItemCF、测试	时间与候选规则通过自动检查
M2	第 5-7 周	SASRec-CE、稠密检索、TIGER 与 LIGER	基线偏差可解释，结果可重跑
M3	第 8-10 周	动态库重放与可达性分析	得到值得研究的差异或明确否定证据
M4	第 11-13 周	滚动路由训练与核心消融	与固定混合在同等预算下比较
M5	第 14-16 周	第二领域、统计检验、失败分析	结论不依赖单种子或单数据切片
M6	第 17-20 周	C++ 优化、演示、论文式报告与复现	他人可运行关键实验并理解贡献

计算资源

初始实验以中小规模推荐 Transformer 为主，模型参数规模由学习曲线与基线配置决定，不强制从十亿参数模型起步。单张 24 GB 显存 GPU 可作为首轮估算配置，实际 batch 与序列长度须通过 smoke run 确认；完整多种子、多领域实验建议安排专门算力。

若加入 1.7B 或更大预训练模型迁移，必须独立规划显存、微调方式、时间与成本，不能把现成预训练带来的收益全部归因于本项目方法。OpenOneRec 发布的不同模型有不同数据来源，使用时须检查权重与目标数据的关系。

先测一个 epoch、一次全库评估、一次文本编码与一次路由数据采集。总预算按“试验数 × 每试验实测小时 + 编码 + 路由数据 + 最终多种子验证”估算，并保留约 20% 余量。GPU 小时与价格在选定设备后填写，不虚构总价。

学习优先级

优先掌握线性代数中的向量与矩阵运算、概率中的条件概率和期望、梯度与优化、交叉熵、负采样偏差、PyTorch 数据管道、Transformer 掩码与训练循环。随后学习 RQ-VAE、束搜索、ANN 和实验统计。

你的 C++ 基础会帮助理解数据结构与性能，但推荐算法岗位仍需要你能独立阅读和修改 Python 模型、排查训练问题。项目中每个核心模块都应有自己的推导与调试记录。

15 风险与停止规则

风险	识别信号	应对措施
研究点与已有工作重复	相关论文已有同一机制和协议	更新贡献定位，加入最接近对照
基线过弱产生虚假收益	简单调参即可消除优势	先修复基线，再继续新模型
冷启动样本定义错误	首次目标被提前加入候选库	修正协议，作废受影响结果
路由使用未来信息	特征依赖当前答案或全量统计	增加时间隔离测试并重做实验
路由只在训练窗口有效	验证阶段退化或动作塌缩	校准或采用固定混合，保留负结果
算力被大模型消耗	尚无可靠基线就开始大规模训练	回到能检验假设的最小有效规模
离线收益被误作业务收益	报告出现未经验证的 CTR 提升	更正为对应离线指标和人群
前端或部署挤占研究	页面完善但没有消融报告	先完成 M5，再做展示增强

若两轮预先设定的路由方案在验证集均不优于最强固定混合，停止无上限增加网络复杂度；分析数据分组、计算成本和可达性瓶颈，形成明确结论。测试集不用于反复寻找下一轮改进方向。

16 展示与面体验收

三分钟演示脚本

第一分钟展示一个带时间的真实历史样例、可用商品库和推荐结果；解释新商品为什么没有训练交互，以及什么情况下它仍能被内容模型找到。

第二分钟重放一次物品库更新，展示生成式、稠密和路由策略的候选差异、合法性检查与耗时。样例提前冻结，同时准备一个失败样例，避免只选成功案例。

第三分钟展示主结果表、最重要的消融与置信区间；说明哪些结果来自个人改进、哪些来自已有代码，以及当前还不能证明什么。

必须能回答的问题

- 1. 生成式推荐与用大模型写推荐理由有什么区别？
- 2. 语义 ID 为何会碰撞，约束解码为何不能保证推荐到所有新商品？
- 3. 你的冷启动定义与真正零反馈上架有什么区别？
- 4. 为什么不用随机切分，为什么不能把目标商品补进候选？
- 5. 稠密基线和 LIGER 已经很强，你的新增贡献在哪里？
- 6. 路由器如何学习动作选择，它看到的信息在预测时是否真的可用？
- 7. 怎样证明收益不是更多候选、更大模型或额外计算造成的？
- 8. 如果整体指标下降、冷组提升，你如何决定是否部署？
- 9. 三个种子与用户 bootstrap 分别说明什么？
- 10. C++ 优化减少了哪一部分耗时，端到端收益是多少？

简历表述规则

完成后可按以下结构写，方括号内容全部来自报告，未实测项不填：

“围绕动态物品库下的生成式推荐，构建全局时间重放与冷物品评估协议，复现 SASRec、TIGER、LIGER 等基线；设计基于请求历史与物品库状态的预算路由，在 [数据领域与协议]、[硬件与预算] 下，取得 [离线指标差值和统计结果]，并完成 [具体 C++ 组件] 的推理优化。”

若改进未获得稳定支持，可写复现、诊断和系统结论，不能填写预计收益。不得出现未经验证的“工业级百万 QPS”“线上 CTR 提升”或“首次提出”。

17 开发启动任务

第一批工作按依赖顺序执行，完成后再进入模型创新。

顺序	任务	产物
1	建立研究仓库与许可证清单	README、环境文件、第三方来源说明
2	下载单一领域并统计字段	data_card.md、数据 manifest
3	实现两个评估轨与候选库重放	protocol.yaml、时间与泄漏测试
4	跑通 Popularity 与 ItemCF	第一张真实基线结果表
5	复现稠密模型与 SASRec-CE	可重复训练和全库评估
6	复现 TIGER 与 LIGER	官方协议复现差异报告

顺序	任务	产物
7	诊断新商品与语义路径	冷组报告、可达性与前缀图表
8	冻结研究假设与主比较	experiment_plan.yaml

建议目录为 data_pipeline、models、routing、evaluation、catalog、serving、configs、tests 和 reports。目录体现问题边界，不提前拆成大量微服务。

18 参考资料与使用方式

以下来源于 2026 年 9 月 13-14 日核查。论文结论以其数据、实现和实验条件为限；近期预印本不等同已经同行评审。这里列出的资料是选题与设计依据，不是本项目已完成的实验。

- 1. [百度推荐算法实习岗位](#)：理解岗位涉及的行为建模和算法基础；投递时重新核实状态。
- 2. [TIGER 论文](#)：理解语义 ID 与生成式检索的基本路线。
- 3. [LIGER 官方代码](#)：作为最接近的混合检索基线；其代码和子模块许可须分别检查。
- 4. [语义 ID 冷启动的时间视角](#)：近期预印本，辅助设计可达性和冷组诊断。
- 5. [OpenOneRec 官方项目](#)：了解工业研究方向与开放模型，单独检查训练来源与权重许可。
- 6. [Meta Generative Recommenders](#)：了解 HSTU 等架构与系统实践。
- 7. [Amazon Reviews 2023 数据说明](#)：核查交互与商品字段、数据获取方式。
- 8. [Amazon 官方预处理与切分](#)：理解去重、过滤和全局时间切分。
- 9. [SASRec 原始论文](#)：建立序列推荐基线的原理认识。
- 10. [Time to Split](#)：检查序列推荐的离线评估协议与强基线问题。
- 11. [Faiss 官方文档](#)：实现与验证稠密向量检索。

文档验收：目标、范围、数据合同、算法假设、最接近基线、功能、接口、指标、实验、资源、风险和最终交付均已定义。项目代码、模型训练和实测报告属于后续实施阶段。